



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería en Informática



TFG del Grado en Ingeniería Informática

**Sistema de reconocimiento
automático en arqueobotánica**



Presentado por Jaime Sagüillo Revilla
en Universidad de Burgos — 2 de mayo de 2017
Tutores: Álgvar Arnaiz González, José Francisco Díez
Pastor y Virginia Ahedo García



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería en Informática



Álvar Arnaiz González, José Francisco Díez Pastor profesores del departamento de Departamento de Ingeniería Civil, Área de Lenguajes y Sistemas Informáticos.

Expone:

Que el alumno D. Jaime Sagüillo Revilla, con DNI 12782524-K, ha realizado el Trabajo final de Grado en Ingeniería Informática titulado Sistema de reconocimiento automático en arqueobotánica.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección del que suscribe, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 2 de mayo de 2017

Vº. Bº. del Tutor:

Vº. Bº. del co-tutor:

D. nombre tutor

D. nombre co-tutor

Resumen

Descriptores

Arqueobotánica, Fitolito, Reconocimiento de imagenes, Python

Abstract**Keywords**

Índice general

Índice general	III
Índice de figuras	V
Índice de tablas	VI
Introducción	1
Objetivos del proyecto	2
Conceptos teóricos	3
3.1. Inteligencia artificial	4
3.2. Aprendizaje automático	4
3.3. Aprendizaje supervisado y no supervisado	4
3.4. Clasificación	5
3.5. Reconocimiento de patrones	5
3.6. Segmentación	5
3.7. Binarización	5
3.8. Thresholding	6
3.9. Descriptores visuales	6
3.10. <i>Bag of Words</i>	6
3.11. Reconocimiento de objetos contra Detección de objetos	6
3.12. Media promedio de precisión (<i>mAP</i>)	7
3.13. <i>YOLO</i>	7
Técnicas y herramientas	9
4.1. Lenguajes de programación	9
4.2. <i>Anaconda</i>	10
4.3. Control de versiones: <i>Git</i>	11
4.4. Repositorio: <i>Github</i>	11

<i>ÍNDICE GENERAL</i>	IV
4.5. Librerías auxiliares	12
4.6. Documentación: \LaTeX	12
4.7. Entorno de desarrollo: <i>JetBrains PyCharm</i>	12
4.8. Herramienta de prototipado: <i>NinjaMock</i>	13
Aspectos relevantes del desarrollo del proyecto	14
5.1. Procesamiento de imágenes	14
5.2. Clasificadores	15
Trabajos relacionados	20
Conclusiones y Líneas de trabajo futuras	21
Bibliografía	22

Índice de figuras

3.1. Comparativa entre los distintos sistemas de detección de objetos sobre el mismo conjunto de entrenamiento y sobre la misma configuración [4].	8
4.2. Ejemplo de diagrama <i>burndown</i> de un <i>sprint</i>	11
5.3. Conversión de la imagen original a escala de grises	15
5.4. Distintos ejemplos de una imagen segmentada	16
5.5. Resultados obtenidos mediante transformación divisoria	17
5.6. Resultados tras aplicar el clasificador sobre una imagen	19

Índice de tablas

Introducción

Objetivos del proyecto

Conceptos teóricos

Para la comprensión de este proyecto será necesario la comprensión de algunos conceptos teóricos que introduciré en este apartado:

- Inteligencia artificial
- Aprendizaje automático
- Aprendizaje supervisado y no supervisado
- Clasificación
- Reconocimiento de patrones
- Segmentación
- Binarización
- *Thresholding*
- Descriptores visuales
- *Bag of Words*
- Detección de objetos
- mAP
- YOLO

3.1. Inteligencia artificial

Inteligencia artificial, que comúnmente aparece como las siglas IA o AI del inglés, consiste en otorgar a las máquinas la capacidad de realizar acciones que habitualmente son realizadas por humanos, imitando la inteligencia cognitiva humana [1]. Esta podría ser una posible definición de Inteligencia artificial, pero existen multitud [5]. Algunos posibles ejemplos conocidos por todos en los que se aplica la IA son el coche autónomo, videojuegos, asistentes personales, reconocimiento facial en imágenes.

3.2. Aprendizaje automático

Aprendizaje automático, o en inglés *machine learning*, es un campo de la informática cuyo objetivo es dar a los computadores la capacidad de aprender sin explícitamente haber sido programados[12]. Por lo tanto, se encarga de construir modelos para problemas en los que un algoritmo programado no puede conseguir buenos resultados o es muy complejo hacer que lo sean.

3.3. Aprendizaje supervisado y no supervisado

En esta sección vamos a distinguir entre aprendizaje supervisado y no supervisado, ambas técnicas pertenecientes al campo de la informática *machine learning*.

Aprendizaje supervisado es una técnica que consiste en la inferencia de una función partiendo de un conjunto de datos de entrenamiento etiquetado [15]. Para tareas de clasificación o regresión. Es decir, para tareas en las que el resultado deseado sea obtener una variable que nos informe a que clase pertenece una determinada instancia, lo cual es un valor discreto, o para tareas en las que se desea obtener un valor continuo. Dos posibles ejemplos, a modo de aclaración, podrían ser: la clasificación de *emails* en *spam* o *no spam* y la predicción del valor de un inmueble.

En cuanto al otro tipo de aprendizaje, el aprendizaje no supervisado consiste en la obtención de la estructura oculta en los datos. Pero al contrario que en el aprendizaje supervisado, partiendo de un conjunto de datos sin etiquetar, es decir, datos para los cuales no poseemos su valor deseado[16]. Un posible ejemplo de la utilización de este tipo de aprendizaje podría ser la categorización de clientes en varios grupos con fines comerciales.

3.4. Clasificación

Clasificación es la tarea de identificar, entre un conjunto de categorías o clases¹, a que categoría o clase pertenece una determinada instancia.

En el caso de este proyecto, estamos tratando de clasificar los distintos tipos de fitolitos. Por lo tanto tendremos tantas clases como tipos de fitolitos, además, de una clase que indica que no existe fitolito, es decir, negativos.

3.5. Reconocimiento de patrones

El reconocimiento de patrones consiste en la extracción de propiedades similares entre las distintas instancias de una clase [14]. De manera que podamos identificar un determinado objeto en función de los patrones que contiene este. Este concepto, como podemos observar, está íntimamente relacionado con el concepto de clasificación y *machine learning*.

3.6. Segmentación

La segmentación en el campo de la visión artificial, como se indica en la wikipedia, consiste en subdividir una imagen en varios pixeles u objetos. [11] Cuando segmentamos una imagen, lo que pretendemos hacer es cambiar su representación para poder obtener de esta una mayor utilidad o cantidad de información.

En nuestro caso, segmentamos la imagen para eliminar el fondo de ella y obtener así una imagen con solo su parte delantera. De esta manera, eliminamos el ruido que existe en la imagen y, a su vez, la simplificamos reteniendo la parte de la imagen en la que se encuentran los objetos que nos interesan.

Posteriormente a ese paso, nos interesa, como es obvio, dividir la parte delantera de la imagen resultante en objetos. De este modo, obtendremos cada uno de los objetos por separado de forma idónea.

3.7. Binarización

La binarización de una imagen consiste en la simplificación de los valores de cada pixel a 2 posibles valores, blanco o negro, representando el fondo y el frente de la imagen cada uno de ellos. Esta técnica nos permite conservar únicamente la información que nos interesa, eliminando el resto.

¹Se entiende por clase a cada uno de los tipos de instancia que se desea clasificar. Por ejemplo, en un problema en el que deseamos clasificar imágenes como personas y perros. Las clases serán: persona y perro.

3.8. Thresholding

Es el método mas simple para la segmentación de una imagen, pudiendose utilizar para la binarización de una imagen, como es nuestro caso. Consiste en reemplazar los píxeles por debajo de una determinada constante a píxeles negros, y los que se encuentran por encima a píxeles blancos o viceversa.

Existen distintas maneras de llevar a cabo este proceso, siendo uno de lo más conocidos el método de Otsu. [13]

3.9. Descriptores visuales

Los descriptores visuales, o descriptores de características, son descripciones de las características visuales de los contenidos en imágenes o videos, en nuestro caso de imágenes, con el proposito de la detección de objetos [8]. El objetivo de los descriptores visuales es obtener la información que resulta significativa, eliminando a su vez la que no lo es. Así, utilizaremos la información que el descriptor nos proporciona para detectar los objetos que nos interesan en una imagen. Algunos ejemplos de características son la forma, el color o la textura.

Como se puede imaginar, obtener las características a mano es una tarea complicada y que usualmente no funciona correctamente. Por ello, utilizamos un método de extracción automática de características como es *Histogram of Oriented Gradients*, el cual se basa en los gradientes de la imagen para detectar los distintos objetos que se encuentran en la imagen [10].

3.10. *Bag of Words*

Bag of Words (BoW), o en español bolsa de palabras, es una técnica comúnmente utilizada en la clasificación de documentos [9]. En la que se describe un texto mediante el conjunto de palabras que componen dicho texto.

Pero esta técnica también ha sido aplicada al reconocimiento de objetos en imágenes. Siendo, la técnica que mejores resultados conseguía, hasta la llegada del *Deep Learning*. En este caso, se tratan las características de una imagen como palabras.

3.11. Reconocimiento de objetos contra Detección de objetos

Antes de abordar el siguiente concepto, debemos de comprender la diferencia entre el término reconocimiento de objetos y detección de objetos.

Reconocimiento de objetos es el termino utilizado cuando se desea detectar todos los objetos para los que ha sido entrenado el clasificador. Proporcionándonos el tipo de objeto y las coordenadas de la caja que rodea ese objeto. E, incluso en algunos casos, las probabilidades de que ese objeto sea un verdadero positivo o un falso positivo.

En cuanto a la detección de objetos, en este solo se desea obtener si es objeto o no es objeto. Simplificando el problema anterior, de manera que, pasamos de un problema multiclase a un problema con dos clases. Objeto o no objeto.

3.12. Media promedio de precisión (*mAP*)

La media promedio de precisión, en ingles *mean average precision* (*mAP*), es comúnmente utilizada como una medida de evaluación de la precisión en la detección de objetos.

3.13. *YOLO*

YOLO, o *You Only Look Once*, es una aproximación innovadora en la detección de objetos, considerándose actualmente el estado del arte en esta materia, junto a *Faster RCNN*². Tratando de crear una arquitectura muy rápida pero, a su vez, siendo capaz de soportar un número de clases mayor a 9000 [4].

Versiones

YOLO, actualmente, tiene dos versiones. Y, en cada una de estas versiones, se ha desarrollado una versión pequeña y una normal. En la primera versión de *YOLO* se consiguió llegar a resultados muy positivos, como la capacidad de procesar 45 imágenes por segundo con una precisión de 63.4 *mAP*. Y, con la versión pequeña de este, se llegaron a procesar 155 imágenes por segundo con una precisión de 52.7 *mAP*[3]. Precisiones muy positivas, pero que todavía no estaban a la altura del estado del arte a nivel de precisión.

En la segunda versión, se considera a *YOLO* como el estado del arte, junto a *Faster RCNN*. En esta versión, *YOLO* consigue llegar a una precisión de 76,8 *mAP*, procesando 67 imágenes por segundo, y 78,6 *mAP*, procesando 40 imágenes por segundo. Lo cual, supera a *Faster RCNN* en precisión y rapidez, siendo esta última ampliamente superada [4].³

²Faster RCNN es un detector de objetos en tiempo real con una precisión similar a la última versión de *YOLO*, pero con menor rendimiento en tiempos que *este*

³*Faster RCNN* consigue clasificar una 1 imágenes cada 2 segundos. En cambio, *YOLO* es capaz de procesar 40 imágenes.

Característica diferenciadora de *YOLO*

YOLO otorga un enfoque distinto respecto a sus competidores. Mientras que en otros casos, como *Faster RCNN*, se separan las distintas etapas del procesamiento de una imagen. *YOLO*, he de aquí su nombre, solo necesita de un único «vistazo» para predecir la imagen y obtener las coordenadas, o cajas que rodean a cada uno de los objetos predichos [3].

Por supuesto, esta perspectiva no es tan simple como un giro en el enfoque. Sino que, además, implementa otras características, como la normalización en lotes o la obtención automática del tamaño de las cajas, que la permiten ser la mejor aproximación actual en este campo [4].

Podemos ver una comparativa entre los mejores detectores de objetos actuales con *YOLO* en la figura 3.1. Indicando para cada uno de ellos la precisión y la capacidad de procesamiento de imágenes, en las unidades de media promedio de precisión e imágenes por segundo, respectivamente.

Detection Frameworks	Train	mAP	FPS
Fast R-CNN [5]	2007+2012	70.0	0.5
Faster R-CNN VGG-16 [15]	2007+2012	73.2	7
Faster R-CNN ResNet [6]	2007+2012	76.4	5
YOLO [14]	2007+2012	63.4	45
SSD300 [11]	2007+2012	74.3	46
SSD500 [11]	2007+2012	76.8	19
YOLOv2 288 × 288	2007+2012	69.0	91
YOLOv2 352 × 352	2007+2012	73.7	81
YOLOv2 416 × 416	2007+2012	76.8	67
YOLOv2 480 × 480	2007+2012	77.8	59
YOLOv2 544 × 544	2007+2012	78.6	40

Figura 3.1: Comparativa entre los distintos sistemas de detección de objetos sobre el mismo conjunto de entrenamiento y sobre la misma configuración [4].

Técnicas y herramientas

En esta sección se explicarán las distintas técnicas y herramientas utilizadas para llevar a cabo el proyecto.

4.1. Lenguajes de programación

Python

Python es el lenguaje de programación principal utilizado para el desarrollo de este proyecto. *Python* es un lenguaje de alto nivel, interpretado, estructurado y de código abierto que puede ser usado para tareas de muchos tipos [7].

Python se caracteriza por muchos aspectos. Y tiene múltiples ventajas respecto a otros lenguajes, como la fácil legibilidad de su código, las potentes funciones que incorpora por defecto, la utilización de tipado dinámico y las múltiples librerías de código abierto disponibles para distintas tareas, entre otras. Las ventajas que presenta respecto a otros lenguajes, como pueden ser C o Java, nos llevan a usar este lenguaje como el núcleo de nuestro proyecto.

JavaScript

Javascript es el lenguaje de programación de *HTML* y de la *Web*[6]. En nuestro caso, este es utilizado para la realización del etiquetador de imágenes, puesto que está basado en una aplicación *Web*. No existen alternativas estándar a él. Pero si existen librerías para facilitar el uso del mismo, como *JQuery*, la cual es utilizada en la medida de lo posible.

JSON

JSON, siglas que denotan *JavaScript Object Notation*, es un formato ligero para el intercambio de datos [2]. Se basa en la notación de objetos de

JavaScript, de ahí su nombre. Este es utilizado para el almacenamiento de información en nuestra aplicación, como más tarde veremos.

Existe una posible alternativa a *JSON*, la cual es *XML*. Este es un lenguaje de marcado que puede ser utilizado con el mismo objetivo que *JSON*. Pero *XML* tiene distintas desventajas respecto *JSON*:

- *JSON* es más corto.
- *JSON* es más fácil de leer.
- *JSON* se integra fácilmente con *Python*⁴.

4.2. *Anaconda*

Anaconda es una distribución de *Python* y *R* que facilita las tareas de gestión de paquetes, de entornos y de versiones de lenguajes de programación. Nos permite crear varios entornos con distintas versiones de paquetes o lenguajes de programación. Y nos permite la instalación, desinstalación y actualización de distintos paquetes. Facilitándonos estas tareas en la medida de lo posible.

Anaconda nos provee de muchas ventajas respecto a la utilización de *Python* de manera aislada. La utilización de distintas versiones del mismo lenguaje en un mismo sistema operativo es una problemática que *Anaconda* nos soluciona aislandonos de todos estos problemas. Además, como previamente comentaba sobre la gestión de paquetes, *Anaconda* nos provee de una herramienta, *conda*, para la gestión de paquetes.

A continuación explicaré brevemente los paquetes utilizados.

scikit-image

scikit-image nos proporciona un conjunto de herramientas para el procesamiento de imágenes. En las primeras fases, fue utilizada para distintos aspectos de investigación sobre la problemática a acometer, como la segmentación de imágenes, concepto que más tarde introduciré. Pero finalmente, se utilizó únicamente para la lectura y guardado de imágenes.

Jupyter Notebook

Es una herramienta que nos permite crear *webs* interactivas con código, texto, representaciones de los datos o distintas visualizaciones, como imágenes. Muchos de los productos generados por este proyecto serán de este tipo, como el etiquetador de imágenes que más tarde introduciré.

⁴Python es capaz de traducir, o *parsear*, *JSON* a sus propias estructuras sin que tengamos que realizar ningún paso intermedio.

Gestor de tareas: *ZenHub*

ZenHub es una herramienta para la gestión de proyectos totalmente integrada con *GitHub*. Esta herramienta nos permite obtener diagramas *burn-down*⁵ utilizados en el anexo de planificación del proyecto para el seguimiento del proyecto, véase la figura 4.2. También nos permite obtener un gráfico en el que podemos ver los puntos de historia⁶ en los distintos *sprints*⁷. Y, finalmente, nos proporciona un tablero *kanban* para mejorar el flujo de trabajo.



Figura 4.2: Ejemplo de diagrama *burn-down* de un *sprint*

4.3. Control de versiones: *Git*

El control de versiones es una parte fundamental para la realización de un proyecto. Este nos permite acometer distintas acciones, como comprobar el cambio realizado entre versiones, trabajar en equipo fácilmente o volver a un punto anterior, entre otras cosas. En nuestro caso, utilizamos *Git* como control de versiones.

Git nos proporciona las características que necesitamos. Además de algunas ventajas respecto a otras herramientas, como ser un sistema distribuido o proporcionar una interfaz de comandos muy potente.

4.4. Repositorio: *Github*

Otra herramienta principal, a seleccionar, es el repositorio central, en nuestro caso hemos elegido *Github*. *Github* nos proporciona muchas utilidades y una forma simple de llevar a cabo el proyecto con todas las características

⁵Un diagrama *burn-down* es un gráfico que representa la cantidad de trabajo restante.

⁶Los puntos de historia es una medida del esfuerzo a realizar para completar una tarea.

⁷*Sprint* es un periodo de tiempo en el que el conjunto de las tareas, definidas al principio de este, deben ser finalizadas y revisadas.

necesarias. Es por todas sus características y una previa experiencia con la herramienta por lo que se eligió como nuestro servicio de repositorio central.

4.5. Librerías auxiliares

Para llevar a cabo este proyecto, además de las librerías ya citadas, se han utilizado algunos repositorios auxiliares para llevar a cabo algunas de las tareas. Indico a continuación los repositorios con una breve descripción:

- *Jupyter Dashboards*: es una extensión que nos permitirá mostrar un *Jupyter Notebook* con un estilo más personalizado.
- *IPython File Upload*: es una extensión que nos permitirá subir imágenes desde un *Jupyter Notebook*.
- *darkflow*: es una implementación de *YOLO*, concepto que más tarde introduciremos, utilizado para el reconocimiento automático de fitolitos.

4.6. Documentación: L^AT_EX

La memoria y anexos de este proyecto han sido escritos en L^AT_EX. Este nos proporciona muchas ventajas en contraste con otros editores de documentos, como *Word* o sus alternativas, a la hora de realizar un documento de estas características.

L^AT_EX nos facilita concentrarnos simplemente en el contenido. Supeditando a este la problemática de como debe formatearse el contenido. Por lo tanto, L^AT_EX automatiza muchas de las típicas tareas que llevaríamos a cabo con otro editor de documentos y, además, permite obtener documentos con una altísima calidad.

4.7. Entorno de desarrollo: *JetBrains PyCharm*

El entorno de desarrollo o, por sus siglas *IDE*, es la aplicación utilizada para el desarrollo de la aplicación. Proporcionando múltiples herramientas, desde el auto-completar, hasta *plugins* que permiten comprobar el recubrimiento del código mediante tests, entre otras funcionalidades.

Para esta utilidad se valorarán dos herramientas principalmente: *PyDev* y *JetBrains PyCharm*. Escogiéndose esta última por poseer una mayor cantidad de herramientas integradas, como el control de versiones, distintas opciones para refactorizar el código y un muy buen auto-completar, entre otras características.

4.8. Herramienta de prototipado: *NinjaMock*

La herramienta de prototipado es la aplicación utilizada para un primer diseño de la interfaz de una aplicación. Facilitando la demostración, evaluación y agilizando el proceso de llevar a cabo una interfaz. En nuestro caso se utilizó *NinjaMock*, la cual es una aplicación web que nos permite llevar a cabo esta tarea fácilmente.

Aspectos relevantes del desarrollo del proyecto

5.1. Procesamiento de imágenes

Como primera aproximación al problema que nos concierne, nos hemos enfrentado al procesamiento de imágenes mediante la librería Scikit-image para Python. Mediante esta herramienta trataremos de dar solución a nuestro problema siguiendo los siguientes pasos:

1. Convertimos la imagen a escala de grises
2. Segmentamos los objetos del fondo de la imagen
3. Obtenemos los distintos objetos de la imagen

Convertimos la imagen a escala de grises

La conversión de la imagen original (RGB) a escala de grises viene motivada con el mero objetivo de poder segmentar los objetos del fondo de la imagen mediante el método de *Thresholding*. Solo pudiéndose partir de una imagen en escala de grises. En la figura 5.3 podemos ver los resultados.

Segmentamos los objetos del fondo de la imagen

Una vez tenemos la imagen en escala de grises, procedemos a transformar nuestra imagen en una imagen en blanco y negro o binarizada. Los motivos por los que binarizamos la imagen es para obtener una imagen que sea más significativa para nosotros y además este simplificada. Lo cual nos será útil para facilitarnos su procesamiento.




Figura 5.3: Conversión de la imagen original a escala de grises

Scikit nos proporciona distintos métodos mediante los cuales podemos segmentar una imagen. En la figura 5.4 podemos observar el resultado aplicando distintos métodos, los cuales se van indicando en cada una de las figuras.

Obtenemos los distintos objetos de la imagen

Después de tener la imagen binarizada de la forma más apropiada posible probamos a segmentar los distintos objetos de nuestra imagen.

Transformación divisoria

Transformación divisoria, o en inglés *Watershed segmentation*, es un algoritmo clásico para la segmentación de objetos en una imagen.

Durante las primeras pruebas, la segmentación más interesante hasta el momento ha sido la que se muestra en la figura 5.5. A partir de *Watershed segmentation* con marcado. Más allá de esta segmentación no se ha conseguido nada mejor.

5.2. Clasificadores

La aproximación mediante procesamiento de imágenes no parece la más adecuada visto los resultados obtenidos. Por ello vamos a realizar el estudio sobre una segunda aproximación mediante clasificadores, junto a descriptores visuales.

El primer conjunto de técnicas escogido ha sido una Máquina de Vector Soporte junto al Histograma de los gradientes orientados, la cual es una técnica para la extracción automática de características. Sin embargo, iremos utilizando distintas técnicas para adoptar la que mejor se adapte a nuestra problemática.




Figura 5.4: Distintos ejemplos de una imagen segmentada




Figura 5.5: Resultados obtenidos mediante transformación divisoria

El procedimiento para obtener el clasificador es el siguiente:

1. Crear un conjunto de entrenamiento de imágenes de caras que consideramos que son elementos positivos.
2. Crear un conjunto de entrenamiento de imágenes de no-caras que consideramos que son negativos.
3. Extraer las características del conjunto de entrenamiento mediante un descriptor visual.
4. Entrenar el clasificador.

Finalizado el entrenamiento, ya tenemos nuestro clasificador listo para enviarle nuevas imágenes y que sean clasificadas.

Reconocimiento de imágenes en nuevas imágenes

Para el reconocimiento de objetos en nuevas imágenes, deberemos llevar a cabo los tres siguientes pasos:

1. Dividir la imagen en múltiples fragmentos.
2. Comprobar si cada uno de los fragmentos contiene el objeto.
3. Si existe solapamiento en la detección de objetos, muy común en el uso de este tipo de clasificadores, se deben de combinar dichos solapamientos en uno único.

Cada uno de los fragmentos anteriores se solapa en gran medida. Por lo que origina un problema de sobreconocimiento de objetos, reconociendo donde existe un posible positivo, más de uno, en la mayoría de casos. Por ello, se aplica el tercer paso sobre los objetos reconocidos, que es la eliminación del solapamiento de objetos mediante la técnica de *Non-Maximum supresion*.

Aplicación sobre el reconocimiento de caras


Como previa experimentación con esta metodología, vamos a entrenar el clasificador para el reconocimiento de caras. Y en función de la efectividad del método sobre las caras tomaremos una serie de conclusiones sobre las que decidiremos si llevar a cabo esta solución sobre nuestro problema.

Como explicábamos anteriormente, una vez tenemos nuestro clasificador le enviamos una nueva imagen, como podría ser la presentada en la figura 5.6a. A partir de esta imagen el clasificador nos permitirá obtener las ventanas ⁸ en las que detecta una cara, como vemos en la figura 5.6b. Podemos apreciar que existe más de una ventana alrededor de cada cara. Y finalmente, tras aplicar el método *Non-Maximum supresion* obtenemos el resultado final mostrado en la figura 5.6c.


⁸Se entiende por ventana , en este contexto, a la caja o cuadrilátero que etiqueta un positivo en una imagen.



(a) Imagen original



(b) Imagen después de aplicarla nuestro clasificador



(c) Imagen tras aplicarla *Non-Maximum supresion*

Figura 5.6: Resultados tras aplicar el clasificador sobre una imagen

Trabajos relacionados

Conclusiones y Líneas de trabajo futuras

Bibliografía

- [1] Jack Copeland. What is artificial intelligence?, 2000. [Online; accedido 16-Marzo-2017].
- [2] JSON. Json, 2017. [Online; accedido 1-Mayo-2017].
- [3] Joseph Redmon, Santosh Kumar Divvala, Ross B. Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. 2015. [Online; accedido 28-Abril-2017].
- [4] Joseph Redmon and Ali Farhadi. YOLO9000: better, faster, stronger. 2016. [Online; accedido 2-Mayo-2017].
- [5] Stuart Russell and Peter Norvig. A modern approach. *Artificial Intelligence. Prentice-Hall, Egnlewood Cliffs*, page 5, 1995.
- [6] w3schools. Javascript tutorial — w3schools, 2017. [Online; accedido 1-Mayo-2017].
- [7] Wikibooks. Python programming — wikibooks, the free textbook project, 2017. [Online; accedido 1-Mayo-2017].
- [8] Wikipedia. Visual descriptor — Wikipedia, the free encyclopedia, 2016. [Online; accedido 22-Febrero-2017].
- [9] Wikipedia. Bag-of-words model — wikipedia, the free encyclopedia, 2017. [Online; accedido 2-Mayo-2017].
- [10] Wikipedia. Histogram of oriented gradients — Wikipedia, the free encyclopedia, 2017. [Online; accedido 22-Febrero-2017].
- [11] Wikipedia. Image segmentation — Wikipedia, the free encyclopedia, 2017. [Online; accedido 10-Febrero-2017].

- [12] Wikipedia. Machine learning — Wikipedia, the free encyclopedia, 2017. [Online; accedido 9-Abril-2017].
- [13] Wikipedia. Otsu's method — Wikipedia, the free encyclopedia, 2017. [Online; accedido 8-Febrero-2017].
- [14] Wikipedia. Pattern recognition — Wikipedia, the free encyclopedia, 2017. [Online; accedido 9-Abril-2017].
- [15] Wikipedia. Supervised learning — Wikipedia, the free encyclopedia, 2017. [Online; accedido 9-Abril-2017].
- [16] Wikipedia. Unsupervised learning — Wikipedia, the free encyclopedia, 2017. [Online; accedido 9-Abril-2017].